

LIVRABLE INFRA : Documentation de Déploiement

Projet : Hackathon TechCorp Industries

Rôle : SOUCI Adlen, MERY Téo, DUBUN Killian, MARROC Nathan

1. Choix technique et justification du déploiement

L'architecture d'inférence a été initialement pensée pour un déploiement sur le serveur haute performance Triton Inference Server (NVIDIA).

- **Incident technique** : Lors du montage du conteneur de production, une incompatibilité matérielle/logicielle critique a été identifiée entre le sous-système Linux (WSL2) de l'environnement hôte Windows et la bibliothèque dynamique Python de Triton (*Erreur bloquante* : `unable to load shared library: libtriton_python.so: file too short`).
- **Pivot architectural (Solution)** : Pour garantir la livraison de l'API dans le temps imparti et assurer une stabilité absolue pour l'équipe de développement, un pivot vers le moteur **Ollama** a été réalisé.
- **Avantages retenus** : Ollama offre une conteneurisation robuste, une empreinte mémoire très bien optimisée pour une exécution hybride CPU/GPU, et expose nativement une API REST. Le déploiement a été entièrement industrialisé et versionné à l'aide d'un descripteur docker-compose.yml.

2. Accessibilité réseau pour l'équipe DEV WEB

Le serveur d'inférence a été configuré pour être rendu immédiatement disponible aux développeurs frontend sur le réseau local, permettant un travail en parallèle fluide.

- **Serveur d'inférence** : Opérationnel et encapsulé sous Docker (Conteneur : `techcorp-ollama-prod`).
- **Protocole et Port** : HTTP via le port standard 11434.
- **Règles de sécurité (Pare-feu)** : Ouverture du port en entrée sur la machine hôte configurée via une règle `netsh advfirewall allow` spécifique au Hackathon.
- **Endpoint de production (URL)** : `http://10.15.2.52:11434/api/generate`
- **Intégration API** : Les requêtes doivent utiliser la méthode POST avec un *payload* JSON standard pointant vers le modèle de production définitif.

3. Optimisation des performances et de la précision (Modelfile)

Le modèle *Phi-3.5-Financial* nettoyé a été recompilé dans une version de production nommée *techcorp-phi3-prod*. Afin de répondre aux normes très strictes de l'analyse financière (zéro tolérance à l'hallucination de chiffres), les paramètres d'inférence du moteur ont été lourdement optimisés.

Les réglages suivants ont été injectés au cœur du modèle via le Modelfile :

- **PARAMETER temperature 0.1** (*Paramètre critique*) : Réduction drastique de la "créativité" de l'IA. Le modèle est forcé d'être hautement déterministe et factuel, ce qui sécurise les réponses liées aux bilans comptables ou aux analyses boursières.
- **PARAMETER top_p 0.5** : Restriction ciblée de la sélection des probabilités de mots. Force le modèle à utiliser un vocabulaire soutenu, analytique et strictement professionnel, écartant les tournures de phrases incertaines.
- **PARAMETER num_predict 1024** : Ajustement de la mémoire de génération. Les rapports financiers nécessitant des développements longs, cette limite étendue garantit que l'IA ne s'arrêtera pas de formuler sa réponse en plein milieu d'une phrase.